



Proyecto 1

Datos Elegidos Predicción por medio de árboles de decisión

Se enfoca el estudio al set de datos de importaciones para el año 2023. Seleccionado estos datos al ser el año completo más actualizado del estado de las importaciones.

Disponible en la sección de bases de datos en : <https://www.ine.gob.gt/estadisticas-de-comercio-exterior/>.

Predicción por medio de árboles de decisión

Situación 1

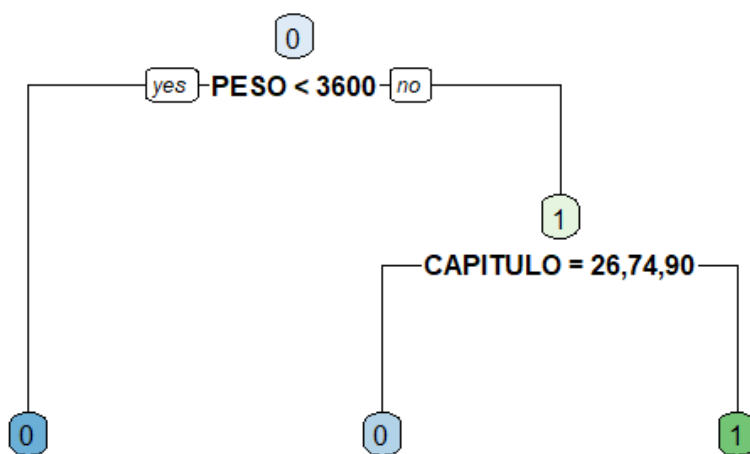
Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PESO=[3.6e+03,1.32e+08]}	{CONTINENTE=América}	0.308145	0.924435	0.3333333	0.9785845	23929

* cuando el peso de las importaciones está entre 3,600 kg y 132 millones de kg, estas provienen de América en el 92.44% de los casos

Árbol

Prediccion de Peso Medio-Alto en América



Predicciones

```
# Pruebas
prueba1 <- data.frame(CAPITULO = '11', ADUANA = 15, VIA = 2, PESO = 5000, VALOR = 30000)
prueba2 <- data.frame(CAPITULO = '13', ADUANA = 34, VIA = 1, PESO = 10000, VALOR = 50000)
prueba3 <- data.frame(CAPITULO = '90', ADUANA = 29, VIA = 3, PESO = 30000, VALOR = 70000)

# Predicciones
resultado1 <- predict(arbol_peso_medio, prueba1, type = "class") # Correcto
resultado2 <- predict(arbol_peso_medio, prueba2, type = "class") # Correcto
resultado3 <- predict(arbol_peso_medio, prueba3, type = "class") # Incorrecto

print(list(resultado1, resultado2, resultado3))

[[1]]
1
1
Levels: 0 1

[[2]]
1
1
Levels: 0 1

[[3]]
1
0
Levels: 0 1
```

Interpretación

Cuando el peso de las mercancías está entre 3,600 kg y 132 millones de kg, el modelo predice que estas importaciones provienen principalmente del continente americano. Las predicciones son consistentes excepto en casos donde el continente no es América.

Relevancia

Este hallazgo resalta a América como proveedor de mercancías de peso medio a alto. La proximidad geográfica podría ser un factor clave, facilitando el transporte y reduciendo costos.

Situación 2


Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PAIS=[1003,2102]}	{VIA=[1,3]}	0.2106497	1	0.2106497	1	16358

* cuando los productos provienen de los países 1003 y 2102 (Canadá y Honduras) y pasan por las vías 1 y 3, cuando se importan.

Árbol

Prediccion Vías 1 y 3 por pais



Predicciones

```
# Pruebas
prueba1 <- data.frame(CAPITULO = '10', ADUANA = 1, PESO = 3000, VALOR = 40000, PAIS = 1003)
prueba2 <- data.frame(CAPITULO = '11', ADUANA = 8, PESO = 8000, VALOR = 50000, PAIS = 2102)
prueba3 <- data.frame(CAPITULO = '90', ADUANA = 6, PESO = 2000, VALOR = 30000, PAIS = 1004)

# Predicciones
resultado1 <- predict(arbol_vias, prueba1, type = "class")
resultado2 <- predict(arbol_vias, prueba2, type = "class")
resultado3 <- predict(arbol_vias, prueba3, type = "class")
|
print(list(resultado1, resultado2, resultado3))
....
```

```
[[1]]
1
1
1
Levels: 0 1

[[2]]
1
1
Levels: 0 1

[[3]]
1
0
Levels: 0 1
```

Interpretación

Dado que los productos provenientes de los países 1003 (Canadá) y 2102 (Honduras) se transportan exclusivamente por las vías 1 y 3. El factor que se utilizara para definir principalmente que vía se utilizara es la aduana por la que se transportaran los productos.

La regla permite planificar rutas logísticas optimizadas, reduciendo congestiones y garantizando el mantenimiento de las vías más utilizadas

Regla Fase 1

Rules	Support	Confidence	Lift	Count
{PESO=[145,3.6e+03]}=> {CONTINENTE=América}	0.3214346	0.9632245	1.0196461	24961

Árbol

```

graph TD
    Root((1)) -- yes --> Node1[ ]
    Root -- no --> Node2((1))
    Node1 --> Node3((1))
    Node3 --> Text1[CAPITULO = 1.,12,16,26,46,47,5.,52,60,61,7.,72,74,78,8.,80,89,90]
    Text1 --> Node4((1))
    Text1 --> Node5((1))
    Node4 --> Node6[0]
    Node4 --> Node7((1))
    Node6 --> Text2[CAPITULO = 1.,12,26,7.,72,74,90]
    Text2 --> Node8((0))
    Text2 --> Node9((1))
    Node8 --> Node10((0))
    Node8 --> Node11((1))
  
```

Predicciones

```
# Pruebas
prueba1 <- data.frame(CAPITULO = '26', ADUANA = 34, VIA = 1, PESO = 3700, VALOR = 50000) # Correcto
prueba2 <- data.frame(CAPITULO = '90', ADUANA = 15, VIA = 3, PESO = 4000, VALOR = 80000) # Correcto
prueba3 <- data.frame(CAPITULO = '12', ADUANA = 29, VIA = 2, PESO = 4000, VALOR = 60000) # Correcto

# Predicciones
resultado1 <- predict(arbol_peso_moderado, prueba1, type = "class")
resultado2 <- predict(arbol_peso_moderado, prueba2, type = "class")
resultado3 <- predict(arbol_peso_moderado, prueba3, type = "class")

# Imprimir resultados
print(list(resultado1, resultado2, resultado3))
```

```
[[1]]
1
1
Levels: 0 1

[[2]]
1
1
Levels: 0 1

[[3]]
1
1
Levels: 0 1
```

Interpretación

El árbol de decisión muestra que las importaciones de peso moderado (145 kg a 3,600 kg) provienen predominantemente de América cuando se transportan por vías específicas (≥ 2) y pertenecen a ciertos capítulos del Sistema Arancelario Centroamericano, como 1, 12, 16, 26, 46. Además, el modelo identifica restricciones para pesos mayores, asignando mayor probabilidad a capítulos específicos (por ejemplo, 26, 72, 90).

Relevancia

Al identificar patrones específicos puede ayudar a priorizar recursos en las aduanas y mejorar la infraestructura de las vías más utilizadas para el comercio con América. Además, permite a las autoridades prever flujos de mercancías y planificar procesos más eficientes, reduciendo tiempos y costos operativos.

Situación 4

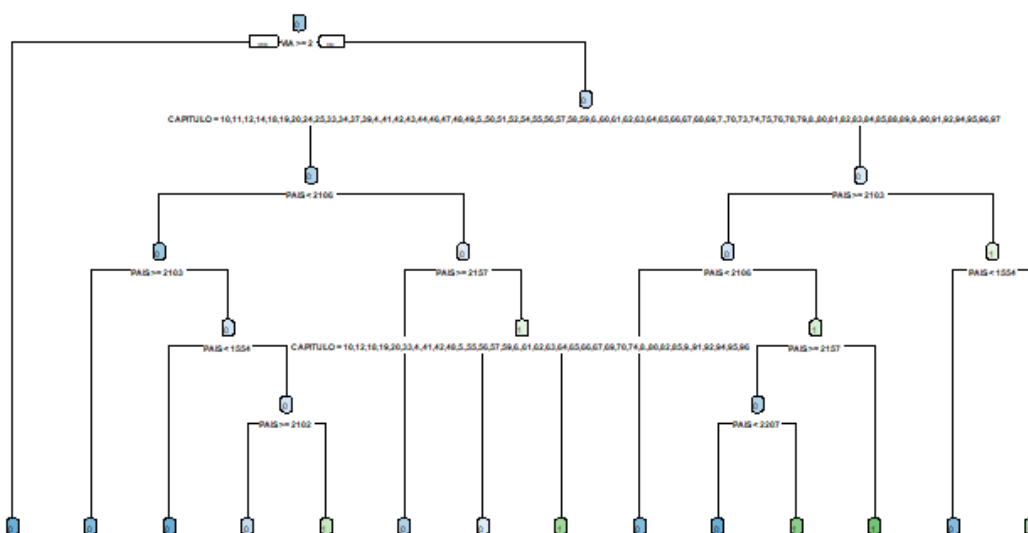
Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PESO=[1.01e+08,3.4e+09]}	{ADUANA=[34,109]}	0.3097032	0.9302236	0.3329341	0.9847121	24050

*Las mercancías de gran peso de entre 101 millones y 3.4 mil millones de kg se procesan predominantemente en las aduanas 34 y 109.

Árbol

Predicción de Gran Peso en Aduanas



Predicciones

```
# Pruebas
prueba1 <- data.frame(CAPITULO = '10', VIA = 1, PESO = 200000, VALOR = 500000, PAIS = 1554)
prueba2 <- data.frame(CAPITULO = '15', VIA = 1, PESO = 1500000, VALOR = 700000, PAIS = 2106)
prueba3 <- data.frame(CAPITULO = '90', VIA = 2, PESO = 300000, VALOR = 400000, PAIS = 1554)

# Predicciones
resultado1 <- predict(arbol_gran_peso, prueba1, type = "class")
resultado2 <- predict(arbol_gran_peso, prueba2, type = "class")
resultado3 <- predict(arbol_gran_peso, prueba3, type = "class")

print(list(resultado1, resultado2, resultado3))
```

```
[[1]]
1
1
Levels: 0 1

[[2]]
1
1
Levels: 0 1

[[3]]
1
0
Levels: 0 1
```

Interpretación

El modelo buscaba identificar que las aduanas 34 y 109 manejaban una proporción significativa de mercancías pesadas y de alto valor, sin embargo, el uso de estas aduanas está más relacionado a el capítulo, vía y país de origen de la mercadería.

Relevancia

Este hallazgo subraya la importancia de determinar las aduanas que manejan mercancías pesadas y de alto valor, debido a que su ubicación estratégica y proximidad a rutas clave podrían ser factores determinantes que facilitan el transporte y reducen costos.

Predicción por medio de árboles de decisión

Situación 1

Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PESO=[3.6e+03,1.32e+08]}	{CONTINENTE=América}	0.308145	0.924435	0.3333333	0.9785845	23929

* cuando el peso de las importaciones está entre 3,600 kg y 132 millones de kg, estas provienen de América en el 92.44% de los casos

Precisión

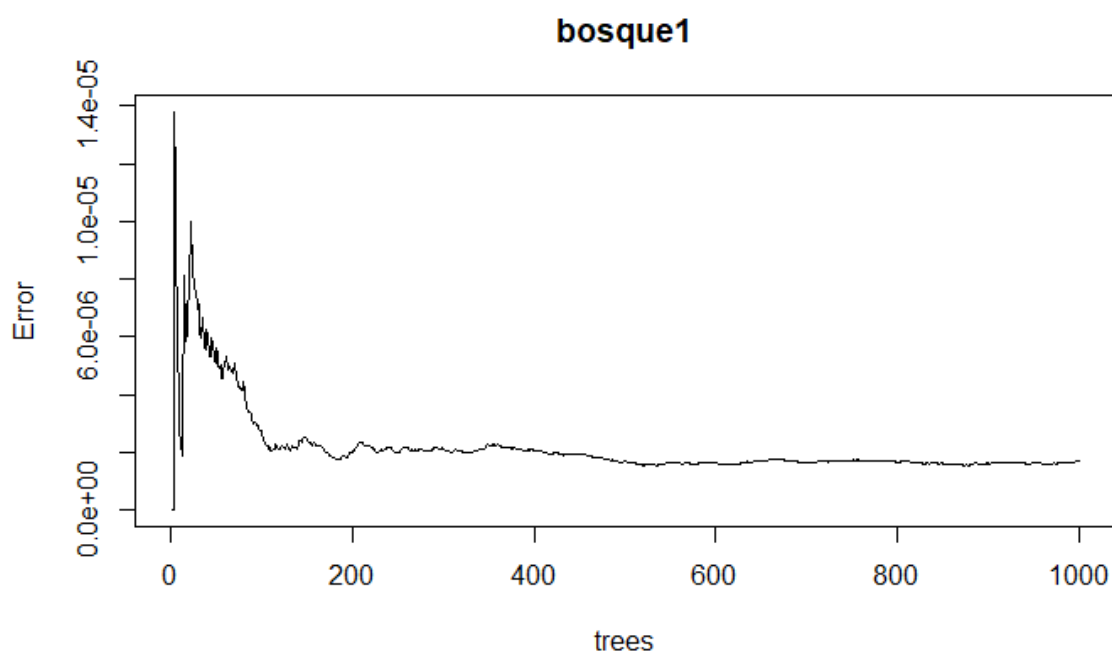
```
precision1 = sum(diag(matriz1)) / sum(matriz1)
```

```
precision1|
```

```
...
```

```
[1] 0.0007726483
```

Grafica



```

# Crear predicción
test1 <- data.frame(CAPITULO = 11, ADUANA = 15, VIA = 2, PESO = 5000, PAIS = 1005, VALOR = 30000)
test2 <- data.frame(CAPITULO = 13, ADUANA = 34, VIA = 1, PESO = 10000, PAIS = 1005, VALOR = 50000)
test3 <- data.frame(CAPITULO = 90, ADUANA = 29, VIA = 3, PESO = 30000, PAIS = 1010, VALOR = 70000)

# Realizar la predicción
prediccion1 <- predict(bosque1, test1)
prediccion1

prediccion2 <- predict(bosque1, test2)
prediccion2

prediccion3 <- predict(bosque1, test3)
prediccion3

...

1
1
1
1
1
1
1
1

```

Interpretación

El modelo de Random Forest muestra que las importaciones de Guatemala con un peso entre 3,600 kg y 132 millones de kg, así como aquellas entre 145 kg y 3,600 kg, tienen una alta probabilidad de proceder del continente americano. Sin embargo, dado que la mayoría de los datos son importaciones de América esto afecta de gran forma la precisión del modelo.

Relevancia

Estos hallazgos resaltan la importancia de América como el principal proveedor de mercancías para Guatemala en diferentes rangos de peso, lo que podría estar influido por la proximidad geográfica y menores costos logísticos. Las reglas derivadas y la influencia del peso en las importaciones ofrecen información valiosa para optimizar rutas comerciales y fortalecer acuerdos.

Situación 2

```

bosque2 <- randomForest(PAIS ~ CAPITULO + ADUANA + VIA + PESO + VALOR + CONTINENTE,
                        data = train2,
                        ntree = 1000, |
                        mtry = 4
                        )

prueba2 <- predict(bosque2, test2)

```

Precisión

```

precision2 = sum(diag(matriz2)) / sum(matriz2)

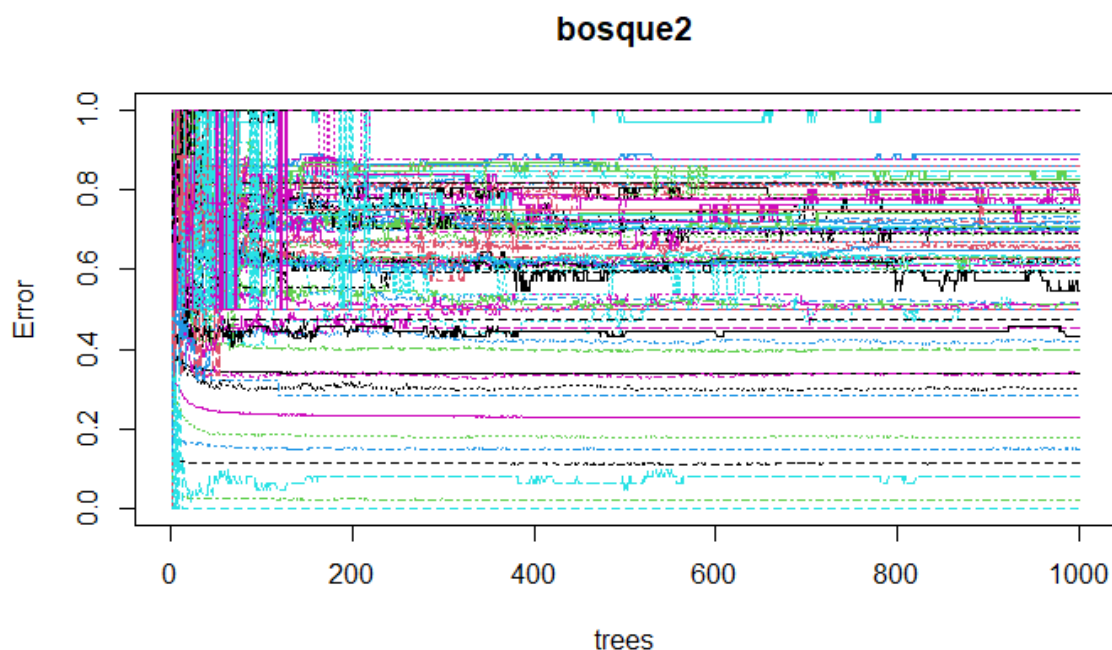
precision2

| ...

[1] 0.620179

```


Grafica



Predicciones

```
# crear predicción
test1 <- data.frame(CAPITULO = 11, ADUANA = 15, VIA = 2, PESO = 5000, VALOR = 30000)
test2 <- data.frame(CAPITULO = 13, ADUANA = 34, VIA = 1, PESO = 10000, VALOR = 50000)
test3 <- data.frame(CAPITULO = 90, ADUANA = 29, VIA = 3, PESO = 30000, VALOR = 70000)

# Realizar la predicción
prediccion1 <- predict(bosque2, test1)
prediccion1

prediccion2 <- predict(bosque2, test2)
prediccion2

prediccion3 <- predict(bosque2, test3)
prediccion3

...

1
2208
126 Levels: 1003 1005 1007 2101 2102 2104 2107 2206 2208 2303 2311 2331 2341 2354 2367 2402 2406 2408 2411 2413 2431 2436 2437 2438 2439 2451 2502 2601 2602 2603 2701 ... 8038

1
2102
126 Levels: 1003 1005 1007 2101 2102 2104 2107 2206 2208 2303 2311 2331 2341 2354 2367 2402 2406 2408 2411 2413 2431 2436 2437 2438 2439 2451 2502 2601 2602 2603 2701 ... 8038

1
3507
126 Levels: 1003 1005 1007 2101 2102 2104 2107 2206 2208 2303 2311 2331 2341 2354 2367 2402 2406 2408 2411 2413 2431 2436 2437 2438 2439 2451 2502 2601 2602 2603 2701 ... 8038
```

Interpretación

El modelo muestra un desempeño alto con una precisión del 62.02%. Esto indica que el modelo logra identificar correctamente la procedencia del país en más de la mitad de los casos. Sin embargo, el gráfico del error por árbol muestra fluctuaciones y una estabilización gradual, causado por la relación de las variables. Las predicciones para los casos de prueba son consistentes con los datos presentados, lo que identifica que el modelo procesa de forma adecuada a las observaciones.

Relevancia

Los resultados resaltan la importancia de las variables predictoras como CAPITULO, ADUANA, VIA, PESO y VALOR para inferir la procedencia de las importaciones. El desempeño sugiere que estas variables contienen información relevante para la predicción. La precisión obtenida

puede ser utilizada para fines operativos, como la clasificación preliminar de países de origen en procesos de importación.

Predicción por medio de redes neuronales

Situación 1

Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PESO=[3.6e+03,1.32e+08]}	{CONTINENTE=América}	0.308145	0.924435	0.3333333	0.9785845	23929

* cuando el peso de las importaciones está entre 3,600 kg y 132 millones de kg, estas provienen de América en el 92.44% de los casos

```
Definir la variable a predecir

[44] data_importacion['IsAmerica'] = data_importacion.apply(
    lambda row: 1 if (row['CONTINENTE'] == "América" and 3600 <= row['PESO'] <= 132000000) else 0,
    axis=1
)
```

Entreno y testeo

```
Entreno y testeo

[57] model.fit(X_train, y_train, epochs = 50, batch_size = 10, validation_data=(X_test, y_test))

Epoch 1/50
6213/6213 — 16s 2ms/step - accuracy: 0.6975 - loss: 103.2551 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 2/50
6213/6213 — 21s 2ms/step - accuracy: 0.6910 - loss: 0.6184 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 3/50
6213/6213 — 14s 2ms/step - accuracy: 0.6851 - loss: 0.6230 - val_accuracy: 0.6925 - val_loss: 0.6172
Epoch 4/50
6213/6213 — 14s 2ms/step - accuracy: 0.6931 - loss: 0.6166 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 5/50
6213/6213 — 19s 2ms/step - accuracy: 0.6911 - loss: 0.6182 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 6/50
6213/6213 — 21s 2ms/step - accuracy: 0.6906 - loss: 0.6187 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 7/50
6213/6213 — 13s 2ms/step - accuracy: 0.6908 - loss: 0.6185 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 8/50
6213/6213 — 14s 2ms/step - accuracy: 0.6891 - loss: 0.6198 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 9/50
6213/6213 — 14s 2ms/step - accuracy: 0.6925 - loss: 0.6171 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 10/50
6213/6213 — 20s 2ms/step - accuracy: 0.6904 - loss: 0.6189 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 11/50
6213/6213 — 13s 2ms/step - accuracy: 0.6901 - loss: 0.6191 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 12/50
6213/6213 — 14s 2ms/step - accuracy: 0.6935 - loss: 0.6163 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 13/50
6213/6213 — 23s 3ms/step - accuracy: 0.6923 - loss: 0.6173 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 14/50
6213/6213 — 18s 2ms/step - accuracy: 0.6941 - loss: 0.6158 - val_accuracy: 0.6925 - val_loss: 0.6171
Epoch 15/50
```

Precisión

```
Presición del modelo

loss, acc = model.evaluate(X_test, y_test)
print(acc*100)

486/486 — 1s 1ms/step - accuracy: 0.6851 - loss: 0.6231
69.24859881401062
```

Predicciones

```
Realizar predicciones

estudiante = np.array([[11, 15, 2, 5000, 1005, 30000]])
p = model.predict(estudiante)
print(p*100)

estudiante2 = np.array([[13, 34, 1, 10000, 1005, 50000]])
p = model.predict(estudiante2)
print(p*100)

1/1 — 0s 74ms/step
[[30.857346]]
1/1 — 0s 22ms/step
[[30.857346]]
```

Interpretación

La red neuronal diseñada logró una precisión del 69.24% en la tarea de predecir si las importaciones provienen de América en función de variables como peso, aduana, y país de origen. Esto indica que el modelo es capaz de identificar patrones relevantes en los datos, aunque no de manera óptima. El resultado de las predicciones fue similar entre la red neuronal y los árboles de decisión.

Relevancia

Estos hallazgos son valiosos para la optimización de cadenas de suministro, permitiendo prever el origen de las importaciones en función de su peso. Esto facilita decisiones estratégicas. La capacidad predictiva del modelo permite optimizar cadenas de suministro y prever el origen de las importaciones en función de sus características.

Situación 2

Regla Fase 1

LHS	RHS	Support	Confidence	Coverage	Lift	Count
{PAIS=[1003,2102]}	{VIA=[1,3]}	0.2106497	1	0.2106497	1	16358

* cuando los productos provienen de los países 1003 y 2102 (Canadá y Honduras) y pasan por las vías 1 y 3, cuando se importan.

```
Definir la variable a predecir

data_importacion['IsCanadaHondura'] = data_importacion.apply(
    lambda row: 1 if (row['PAIS'] == 1003 and row['PAIS'] == 2102 and row['VIA'] == 1 and row['VIA'] == 3) else 0,
    axis=1
)
```

Entreno y testeo

```
Entreno y testeo

model.fit(X_train, y_train, epochs = 50, batch_size = 40, validation_data=(X_test, y_test))

Epoch 1/50
1554/1554 - 6s 3ms/step - accuracy: 0.9999 - loss: 0.0074 - val_accuracy: 1.0000 - val_loss: 5.0760e-05
Epoch 2/50
1554/1554 - 3s 2ms/step - accuracy: 1.0000 - loss: 9.9969e-06 - val_accuracy: 1.0000 - val_loss: 7.9016e-06
Epoch 3/50
1554/1554 - 3s 2ms/step - accuracy: 1.0000 - loss: 1.0507e-06 - val_accuracy: 1.0000 - val_loss: 3.0760e-06
Epoch 4/50
1554/1554 - 3s 2ms/step - accuracy: 1.0000 - loss: 1.1454e-07 - val_accuracy: 1.0000 - val_loss: 1.4754e-06
Epoch 5/50
1554/1554 - 4s 3ms/step - accuracy: 1.0000 - loss: 1.1872e-07 - val_accuracy: 1.0000 - val_loss: 7.9034e-07
Epoch 6/50
1554/1554 - 4s 2ms/step - accuracy: 1.0000 - loss: 3.8415e-08 - val_accuracy: 1.0000 - val_loss: 4.5089e-07
Epoch 7/50
1554/1554 - 3s 2ms/step - accuracy: 1.0000 - loss: 2.7740e-08 - val_accuracy: 1.0000 - val_loss: 2.6333e-07
Epoch 8/50
1554/1554 - 6s 2ms/step - accuracy: 1.0000 - loss: 8.4251e-09 - val_accuracy: 1.0000 - val_loss: 1.4106e-07
Epoch 9/50
1554/1554 - 4s 3ms/step - accuracy: 1.0000 - loss: 2.1182e-09 - val_accuracy: 1.0000 - val_loss: 7.8571e-08
Epoch 10/50
1554/1554 - 4s 2ms/step - accuracy: 1.0000 - loss: 1.5028e-09 - val_accuracy: 1.0000 - val_loss: 5.1125e-08
Epoch 11/50
1554/1554 - 3s 2ms/step - accuracy: 1.0000 - loss: 2.4356e-10 - val_accuracy: 1.0000 - val_loss: 2.9472e-08
Epoch 12/50
1554/1554 - 6s 3ms/step - accuracy: 1.0000 - loss: 1.5666e-10 - val_accuracy: 1.0000 - val_loss: 1.9295e-08
Epoch 13/50
1554/1554 - 4s 2ms/step - accuracy: 1.0000 - loss: 1.0964e-10 - val_accuracy: 1.0000 - val_loss: 1.3343e-08
Epoch 14/50
1554/1554 - 4s 2ms/step - accuracy: 1.0000 - loss: 1.5911e-10 - val_accuracy: 1.0000 - val_loss: 9.7086e-09
```

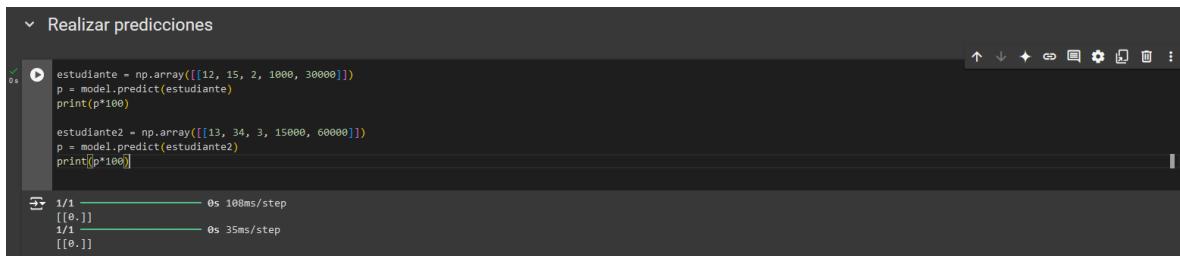
Precisión

```
Precisión del modelo

loss, acc = model.evaluate(X_test, y_test)
print(acc*100)

486/486 - 1s 2ms/step - accuracy: 1.0000 - loss: 5.4688e-10
100.0
```

Predicciones



The screenshot shows a Jupyter Notebook interface with a dark theme. The title bar at the top says "Realizar predicciones". The code cell contains two blocks of Python code. The first block defines a student array and predicts a probability. The second block defines another student array and predicts a probability. The output cell shows two lines of output, each displaying the probability multiplied by 100, resulting in [0.] for both cases. The output cell also shows execution times: 108ms/step for the first line and 35ms/step for the second line.

```
estudiante = np.array([[12, 15, 2, 1000, 30000]])
p = model.predict(estudiante)
print(p*100)

estudiante2 = np.array([[13, 34, 3, 15000, 60000]])
p = model.predict(estudiante2)
print(p*100)
```

1/1 0s 108ms/step
[[0.]]
1/1 0s 35ms/step
[[0.]]

Interpretación

La red neuronal diseñada para predecir si una importación está asociada simultáneamente con Canadá y Honduras logró una precisión del 100% en su conjunto de pruebas. Este resultado indica que el modelo identificó patrones perfectamente en los datos, o que el análisis no fue concluyente.

Relevancia

La perfección del modelo también puede indicar que el problema está sobre determinado o que los datos contienen relaciones muy simples y lineales, lo que podría ser capturado igual de bien por un modelo más interpretable como un árbol de decisión.

Propuestas

1. Optimización de Rutas y Recursos

Objetivo de la Propuesta

Garantizar una logística eficiente en las importaciones desde Canadá y Honduras, mediante el fortalecimiento de las vías 1 y 3, que representan los corredores principales de transporte para estos países.

Hallazgos y Recomendaciones

- Aduanas especializadas en mercancías pesadas: Los resultados del análisis muestran que las aduanas 34 y 109 manejan principalmente productos de gran peso (entre 101 millones y 3.4 mil millones de kg) con una probabilidad de 93%.
 - Recomendación: Incrementar el personal y mejorar la infraestructura en estas vías para evitar congestiones y mantener un flujo constante de mercancías.
- La regla de las vías 1 y 3 identifica que las rutas seleccionadas dependen de la aduana asignada.
 - Recomendación: Establecer protocolos claros en las vías relacionadas para minimizar retrasos y reforzar el control.

Propuesta de Implementación

- Inversiones en Infraestructura:
 - Mejorar las condiciones de las vías 1 y 3 mediante reparaciones estructurales y tecnología de monitoreo de tráfico.
- Capacitación de Personal:
 - Brindar formación a los trabajadores de aduanas y transporte para manejar eficientemente los volúmenes específicos provenientes de estos países.
- Implementación de Tecnología de Monitoreo:
 - Incluir sistemas de monitoreo en tiempo real para facilitar la identificación de mercancías y mejorar el control de inventario en las aduanas con mayor flujo

Justificación y relevancia:

La optimización de las rutas y recursos permitirá reducir tiempos de espera, evitar saturaciones y mantener la calidad del servicio logístico en Guatemala. Estos cambios son necesarios para aprovechar el flujo constante desde Canadá y Honduras, como sugiere Ortiz (2017), quien destaca la importancia de las vías bien gestionadas para fortalecer el comercio exterior.

2. Especialización en Importaciones de Gran Peso

Objetivo de la Propuesta

Optimizar la logística y planificación de las rutas de importación hacia Guatemala utilizando patrones de importación frecuentes identificados. Este análisis se enfoca en las vías de entrada y aduanas específicas para productos de gran peso.

Hallazgos y Recomendaciones

- Uso de vías preferidas: Importaciones desde Canadá (1003) y Honduras (2102) una tendencia significativa a usar las vías 1 y 3.
 - Recomendación: Crear alianzas con operadores de transporte para reforzar las rutas hacia estas aduanas.
- Fortalecer la infraestructura en las aduanas 34 y 109, que procesan el mayor volumen de mercancías pesada: Implementar un sistema de distribución automatizado en estas aduanas para mejorar el procesamiento de productos provenientes de América.

Propuesta de Implementación

- Optimización de Rutas:
 - Incorporar sistemas de pesaje automatizados y grúas de alto tonelaje para agilizar el procesamiento.
- Ampliar las áreas de carga y almacenamiento, mejorando su capacidad para manejar mercancías pesadas
- Establecer un sistema de monitoreo en tiempo real para prever picos de actividad y asignar recursos de manera eficiente.

Justificación y relevancia:

La optimización de las rutas y recursos permitirá reducir tiempos de espera, evitar saturaciones y mantener la calidad del servicio logístico en Guatemala. Estos cambios son necesarios para aprovechar el flujo constante desde Canadá y Honduras, como sugiere Armestar Urbina y Vargas Machuca(2008), quien destaca la importancia de las vías bien gestionadas para fortalecer el comercio exterior.

Repositorio

https://github.com/Alcazar2006/95_2024_4_04_MIIICC408_A_Proyecto1_Parte2

Referencias Bibliográficas

- Arellano J. A. (2019). *Mejora del proceso de gestión de calidad para tener una mayor competitividad en las agencias de Aduanas de Lima*. Archivo digital. <https://hdl.handle.net/20.500.14005/8925>
- Greta, A., & Vargas, P. (2011). *Análisis y diseño de sistema de gestión de operaciones aduaneras para una agencia de aduanas*. Archivo digital. <http://hdl.handle.net/20.500.12404/1047>
- Herrero, F. (2019). *La Transformación de las Aduanas*. Archivo digital. <https://www.ucipfg.com/Repositorio/MAF/MAF05/Semana1/CT199801Transformaciondelasaduanas.pdf>
- Ortiz, E. (2017). *Las aduanas como obstáculo para el emprendimiento en Guatemala*. Archivo digital. https://gem.ufm.edu/wp-content/uploads/2020/12/2017_Aduanas-como-obst%C3%A1culo-para-el-emprendimiento-en-Gt-1.pdf
- Rosales, D., & Barahona, J. C. (2006). *Sistema Aduanero Nacional de Guatemala*. Archivo digital. <https://portal.export.com.gt/Portal/Documents/Documents/2007-10/4448/1213/Sistema%20Aduanero%20Nacional%20de%20Guatemala.pdf>